SMO算法原理及其在SVM求解中的应用

1. SMO算法概述

序列最小优化（Sequential Minimal Optimization, SMO） 是一种用于高效求解支持向量机（SVM）对偶问题的优化算法。由John Platt于1998年提出，主要解决SVM训练过程中的大规模二次规划（QP）问题。

核心思想

- **分解策略**：将大规模QP问题分解为最小规模的子问题（每次只优化两个拉格朗日乘子）
- **启发式选择**：通过启发式规则选择待优化的乘子对
- **解析求解**：对子问题直接进行解析求解（闭式解），避免数值优化

2. 算法原理

2.1 优化目标

SVM的对偶问题形式：

$$\max_{\alpha} \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i,j=1}^{m} \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j)$$

约束条件：

$$0 \leq \alpha_i \leq C, \quad \sum_{i=1}^{m} \alpha_i y_i = 0$$

其中 $K(\cdot)$ 是核函数，C 是惩罚参数。

2.2 关键步骤

1. **乘子选择启发式规则**：
   - 外层循环：选择违反KKT条件最严重的乘子 α_i

- 内层循环：根据最大步长准则选择 α_j

2. **两变量解析解**：
   固定其他乘子，优化目标简化为二元二次函数：

$$\alpha_j^{new} = \alpha_j^{old} + \frac{y_j(E_i - E_j)}{\eta}$$
$$\eta = 2K(\mathbf{x}_i, \mathbf{x}_j) - K(\mathbf{x}_i, \mathbf{x}_i) - K(\mathbf{x}_j, \mathbf{x}_j)$$

   其中 $E_k = f(\mathbf{x}_k) - y_k$ 为预测误差。

3. **裁剪约束**：
   - 考虑边界约束 $0 \leq \alpha_i, \alpha_j \leq C$
   - 线性约束 $\alpha_i y_i + \alpha_j y_j = \zeta$ (常数)

```
if y_i != y_j:
    L = max(0, α_j - α_i)
    H = min(C, C + α_j - α_i)
else:
    L = max(0, α_i + α_j - C)
    H = min(C, α_i + α_j)
```

4. 更新阈值b：

$$b = \begin{cases} b_1, & if 0 \leq \alpha_i \leq C \\ b_2, & if 0 \leq \alpha_j \leq C \\ (b_1 + b_2)/2, & otherwise \end{cases}$$

3. 在SVM中的应用

3.1 求解优势

特性	传统QP解法	SMO解法
时间复杂度	$O(m^3)$	$O(m^2)$~$O(m^3)$ 实际更优
空间复杂度	需存储$m \times m$核矩阵	仅缓存部分核矩阵
数值稳定性	迭代法易累积误差	解析解无累积误差
大规模处理	受内存限制	适合中等规模数据集

特性	传统QP解法	SMO解法
实现复杂度	需专业QP求解器	相对简单易实现

3.2 实现流程

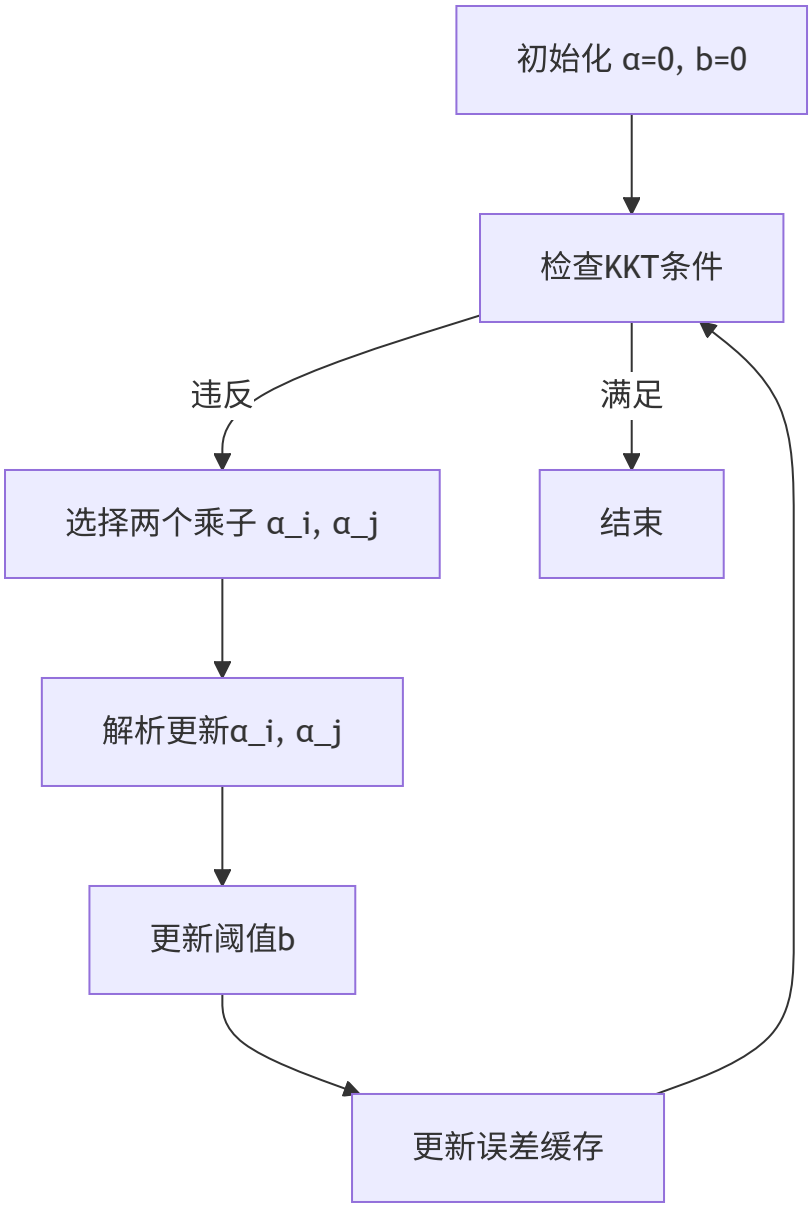

4. 参考

文献